UNIVERSIDAD SANTO TOMÁS
PRIMER CLAUSTRO UNIVERSITARIO DE COLOMBIA
BUCARAMANGA

Facultad de Ingeniería Mecatrónica
Cátedra Análisis de Datos con Python
Parcial Segundo Corte

Estudiante: _____ Código: _____

Recuerde, la interpretación forma parte de la evaluación, por lo tanto, no se responden preguntas. No se permite el intercambio de calculadoras, lápices, borradores ni otros materiales. Los celulares y equipos electrónicos deben permanecer apagados y en modo silencio. Tenga en cuenta el manejo del tiempo. Cualquier intento de fraude es causal de anulación del examen, obteniendo una calificación de 1.0.

Resultados de aprendizaje evaluados:

- Limpia, transforma y explora datasets reales mediante técnicas ETL, análisis exploratorio, feature engineering y visualización de datos, para identificar patrones, relaciones, inconsistencias y oportunidades de mejora.
- Aplica fundamentos de programación en Python y manejo de estructuras de datos, mediante entornos como VS Code, Jupyter Notebook o Google Colab, para desarrollar soluciones básicas de análisis de datos.

Contexto

La empresa PLADESAN ha realizado diferentes campañas de ensayos mecánicos sobre componentes asociados a una cadena cardánica con el propósito de estudiar su comportamiento bajo distintas condiciones de fabricación, materiales y configuraciones de proceso.

Para este parcial se utilizará un conjunto de datos publicado en Kaggle. El acceso se realizará mediante el enlace suministrado en esta guía. El conjunto contiene archivos .txt correspondientes a resultados experimentales realizados durante 2022 y 2024.

Los ensayos no corresponden a una única condición experimental. Dentro de los archivos pueden encontrarse diferencias relacionadas con fecha de ensayo, formulación, muestra o contramuestra, componente, tipo de ensayo, cavidad, tiempo de procesamiento, uso de calzas, temperatura del agua, temperatura o velocidad de inyección y otras condiciones registradas durante las distintas campañas.

Por esta razón, no todos los archivos deben compararse directamente entre sí. Una parte fundamental del trabajo consiste en reconocer la estructura del conjunto de datos, identificar cuáles experimentos pertenecen a condiciones comparables y evitar conclusiones obtenidas a partir de agrupaciones que no tengan sentido experimental.

Estructura general de los archivos

Los archivos .txt fueron generados directamente por el equipo utilizado durante los ensayos. Dependiendo de la prueba, pueden contener información general del ensayo, identificación de la muestra, parámetros de configuración, características geométricas, resultados calculados automáticamente y registros experimentales adquiridos durante la prueba.

En los ensayos de tensión, una de las estructuras principales corresponde a:

```
Time    |    Force    |    Stroke
```

En términos generales, Time representa el tiempo del ensayo, Force la fuerza registrada y Stroke el desplazamiento del sistema de ensayo. El equipo también puede reportar variables resumen como Max_Force, Max_Disp, YP_Force, YP_Disp y parámetros asociados con esfuerzo, deformación o rotura, cuando están disponibles.

Propósito del parcial

Desarrollar un proceso reproducible de análisis de datos mediante Python que permita obtener el conjunto de datos desde Kaggle, explorar archivos experimentales reales, automatizar su lectura, limpiar y transformar los datos, construir estructuras consolidadas, realizar análisis descriptivos, seleccionar visualizaciones apropiadas, comparar condiciones experimentales e interpretar los resultados sin obtener conclusiones que los datos no permitan sustentar.

El objetivo principal no es evaluar conocimientos avanzados de resistencia de materiales, sino la capacidad de utilizar Python para transformar datos experimentales en información organizada, comparable e interpretable.

Obtención del conjunto de datos desde Kaggle

Actividad obligatoria no evaluable

El conjunto de datos requerido para desarrollar el parcial se encuentra disponible en Kaggle. Acceda mediante el siguiente enlace: PLADESAN – Cardan Shaft Test Data 2022–2024 (Kaggle)

Cada grupo deberá ingresar al enlace indicado y utilizar exclusivamente el conjunto de datos publicado para desarrollar el parcial. El dataset no será entregado mediante una carpeta adicional ni mediante archivos individuales enviados directamente por el docente.

Deberá utilizar Python para disponer de los archivos dentro de su entorno de trabajo. El procedimiento utilizado para acceder al dataset deberá quedar incluido al comienzo del notebook.

Una vez obtenidos los archivos, deberá verificar mediante Python la ubicación donde fueron almacenados, la existencia de las carpetas correspondientes a 2022 y 2024, la cantidad de archivos disponibles y la estructura general de directorios.

Esta actividad es obligatoria, pero no tendrá puntaje independiente. Su finalidad es que el análisis pueda reproducirse partiendo del dataset suministrado mediante Kaggle.

No será necesario buscar el dataset manualmente dentro del catálogo de Kaggle. El grupo deberá utilizar el enlace proporcionado en esta guía.

PARTE 1. RECONOCIMIENTO DEL CONJUNTO DE DATOS – 10 puntos

Antes de realizar cálculos sobre los resultados experimentales, explore mediante Python la estructura de carpetas y archivos suministrados.

- Determine cuántos archivos .txt existen en total.
- Determine cuántos corresponden a 2022 y cuántos a 2024.
- Identifique las diferentes campañas o fechas de ensayo disponibles para cada año.
- Determine qué información puede obtenerse directamente a partir de la estructura de carpetas, el nombre del archivo y el contenido del archivo.
- Construya una tabla denominada, por ejemplo, inventario_ensayos, con una fila por archivo e incluya las variables que pueda identificar de manera razonable: Año, Campaña, Archivo, Fórmula, Muestra, Cavidad, Tiempo, Condición y Tipo_Ensayo.

No todas las variables estarán disponibles en todos los archivos. Los valores no identificables deberán tratarse apropiadamente como datos faltantes.

Pregunta de análisis

¿Por qué sería incorrecto asumir que los 158 archivos corresponden a 158 repeticiones de un mismo experimento? Explique utilizando ejemplos encontrados dentro del conjunto de datos.

PARTE 2. LECTURA AUTOMATIZADA DE LOS ARCHIVOS – 15 puntos

Desarrolle un procedimiento que permita procesar automáticamente los archivos .txt. No se aceptará como solución principal escribir manualmente una instrucción diferente para abrir cada archivo.

- Recorrer las carpetas de datos.
- Localizar automáticamente los archivos .txt.
- Leer su contenido.
- Identificar el inicio de la tabla de datos experimentales.
- Extraer las variables necesarias para el análisis.
- Asociar cada observación con la información correspondiente al archivo de origen.

El código deberá poder ejecutarse nuevamente sobre la carpeta suministrada sin modificar manualmente los nombres de los archivos.

PARTE 3. LIMPIEZA Y PREPARACIÓN – 15 puntos

Realice las transformaciones necesarias para disponer de información adecuada para el análisis. Revise como mínimo:

- Separadores decimales.
- Espacios innecesarios.
- Tipos de datos.
- Caracteres no numéricos.
- Valores faltantes.
- Registros representados mediante símbolos como -.-.
- Valores negativos o próximos a cero al comienzo de algunos ensayos.
- Nombres de columnas.
- Unidades.
- Posibles diferencias de estructura entre archivos.

Las decisiones tomadas deberán quedar explicadas mediante comentarios en el código o celdas Markdown.

Pregunta de análisis

En algunos ensayos pueden aparecer valores negativos o pequeñas oscilaciones de fuerza durante los primeros instantes. ¿Deben eliminarse automáticamente? Explique qué decisión tomó y por qué. No se calificará positivamente la eliminación de datos únicamente porque parezcan extraños.

PARTE 4. CONSTRUCCIÓN DE LAS BASES CONSOLIDADAS – 10 puntos

Construya al menos dos DataFrames.

DataFrame 1 – Datos experimentales

Debe contener las observaciones individuales obtenidas durante los ensayos. Una estructura posible es: Anio | Campania | Archivo | Formula | Muestra | Cavidad | Tiempo_condicion | Time | Force | Stroke. Puede incluir variables adicionales.

DataFrame 2 – Resumen por ensayo

Debe contener una fila por archivo o prueba. Incluya como mínimo: año, campaña, fórmula, muestra, cavidad cuando exista, condición experimental, número de observaciones, fuerza máxima, desplazamiento asociado a la fuerza máxima, tiempo en el que ocurre la fuerza máxima, media de la fuerza, mediana de la fuerza y desviación estándar.

Muestre las primeras filas de ambas tablas y las dimensiones obtenidas.

PARTE 5. CASO DE ESTUDIO 1 – ENSAYOS DEL 4 DE OCTUBRE DE 2022 – 15 puntos

Utilice únicamente los ensayos correspondientes a 2022 → Octubre 04 → Cadena Cardánica 1400 y concentre inicialmente el análisis en los archivos de tensión de la cadena correspondientes a las Fórmulas 1, 2 y 3.

No incluya en esta comparación los ensayos identificados explícitamente como compresión del PIN o piñón, ya que corresponden a componentes o tipos de prueba diferentes.

Actividades

- Identifique cuántas muestras existen para cada fórmula.
- Obtenga la fuerza máxima correspondiente a cada ensayo.
- Compare muestra y contramuestra cuando estén disponibles.
- Calcule, por fórmula, los estadísticos descriptivos que considere pertinentes.
- Genere una gráfica Fuerza vs. Desplazamiento para todas las muestras seleccionadas.
- Genere una segunda visualización que facilite la comparación de la fuerza máxima obtenida por las distintas fórmulas.

Preguntas de análisis

1. ¿Cuál fórmula produjo el mayor valor individual de fuerza máxima?
2. ¿Ese resultado es suficiente para afirmar que dicha fórmula presenta un comportamiento superior a las demás? Justifique.
3. ¿Qué diferencias encuentra entre las muestras pertenecientes a una misma fórmula?
4. ¿Cuál fórmula presenta mayor variabilidad entre las muestras disponibles?
5. Teniendo en cuenta el número de ensayos disponibles, ¿qué limitaciones tendría una conclusión general sobre las formulaciones?

PARTE 6. CASO DE ESTUDIO 2 – ENSAYOS DEL 26 DE ABRIL DE 2024 – 20 puntos

Utilice los ensayos 2024 → Abril 26 → Cadena Cardánica 1400. Concentre el análisis principal en los archivos identificados como REGULAR ESTANDAR correspondientes a Fórmula 1 y Fórmula 2, Cavidad 1 y Cavidad 2, y tiempos de 0, 15, 30, 45 y 60 minutos.

Esta estructura permite estudiar simultáneamente tres variables: Fórmula – Cavidad – Tiempo.

Actividades

- Construya una tabla resumen con: Fórmula | Cavidad | Tiempo | Fuerza máxima | Desplazamiento asociado.

- Verifique que para cada fórmula se encuentren correctamente identificados los ensayos correspondientes a las dos cavidades y los diferentes tiempos.
- Construya una gráfica Tiempo de condición vs. Fuerza máxima diferenciando claramente Fórmula 1 y Fórmula 2.
- Incorpore la información correspondiente a la cavidad sin producir una gráfica difícil de interpretar.
- Compare el comportamiento de Cavidad 1 y Cavidad 2.
- Analice si existe una tendencia de la fuerza máxima al aumentar el tiempo de 0 a 60 minutos.
- Construya al menos una visualización adicional que considere útil para interpretar conjuntamente fórmula, cavidad y tiempo.

Preguntas de análisis

1. ¿La fuerza máxima permanece aproximadamente constante o cambia con el tiempo?
2. ¿El comportamiento observado es igual para las dos fórmulas?
3. ¿Existen diferencias sistemáticas entre Cavidad 1 y Cavidad 2?
4. ¿Las diferencias entre cavidades parecen mantenerse durante todos los tiempos evaluados?
5. Identifique el ensayo con mayor fuerza máxima y el ensayo con menor fuerza máxima dentro de este subconjunto.
6. ¿Es apropiado concluir que la condición con el mayor valor individual es necesariamente la mejor condición de proceso? Explique.

Consideración: para muchas combinaciones de fórmula, cavidad y tiempo existe únicamente un ensayo. Por esta razón, diferencie claramente entre describir una tendencia observada y demostrar estadísticamente una diferencia. No presente una observación basada en una única muestra como si fuera una conclusión estadística general.

PARTE 7. COMPARABILIDAD DE LOS DATOS DE 2022 Y 2024 – 10 puntos

1. ¿Todos los resultados de 2022 pueden compararse directamente con todos los resultados de 2024? Justifique.
2. Identifique al menos tres variables o condiciones que deberían controlarse antes de realizar una comparación entre años. Considere componente, tipo de ensayo, condición de fabricación, fórmula, cavidad, tiempo y configuración experimental.
3. Proponga un subconjunto de datos de 2022 y 2024 que considere razonablemente comparable. Indique qué archivos o campañas utilizaría, qué variable compararía, qué condiciones intentaría mantener constantes y qué limitaciones tendría la comparación.

4. Explique por qué una comparación basada únicamente en promedio de 2022 vs. promedio de 2024 podría conducir a una interpretación incorrecta.

Si considera que los datos disponibles no permiten realizar una comparación directa suficientemente controlada, puede llegar a esa conclusión, pero deberá demostrarlo mediante el análisis de la información disponible.

PARTE 8. CONCLUSIONES Y COMUNICACIÓN DE RESULTADOS – 5 puntos

Presente entre cuatro y seis conclusiones obtenidas durante el parcial. Como mínimo deberá incluir una conclusión relacionada con los datos de 2022, una relacionada con la campaña de abril de 2024, una relacionada con la variabilidad y una relacionada con las limitaciones del conjunto de datos.

Cada conclusión deberá estar respaldada por una tabla, un estadístico, una gráfica o una comparación cuantitativa. Evite expresiones como “se observa claramente”, “es mucho mejor” o “es evidente” si no presenta evidencia cuantitativa que sustente la afirmación.

REQUISITOS DEL NOTEBOOK

La entrega deberá realizarse mediante un único archivo *.ipynb*, nombrado de la siguiente manera:

`Apellidos_Parcial_AnalisisDatos_PLADESAN.ipynb`

El notebook deberá estar organizado mediante títulos y celdas Markdown. Se recomienda la siguiente estructura:

1. Información de los estudiantes y descripción del problema.
2. Obtención del dataset desde Kaggle.
3. Verificación de archivos e importación de librerías.
4. Reconocimiento del conjunto de datos y lectura automatizada.
5. Limpieza y preparación.
6. Construcción de los DataFrames.
7. Análisis de 2022.
8. Análisis de 2024.
9. Análisis de comparabilidad 2022–2024.
10. Conclusiones.

REPRODUCIBILIDAD

El notebook deberá ejecutarse desde el comienzo hasta el final sin necesidad de modificar manualmente nombres de archivos durante el procesamiento. Una vez obtenido el dataset desde Kaggle, el código deberá identificar y procesar automáticamente la estructura de directorios disponible.

No se aceptará como solución principal copiar los datos manualmente a Excel, construir manualmente una tabla con los resultados, introducir manualmente las fuerzas máximas encontradas en los archivos, cargar uno por uno los archivos mediante instrucciones independientes o reorganizar manualmente los archivos para facilitar el análisis.

El procesamiento deberá realizarse mediante Python.

CRITERIOS DE EVALUACIÓN

Componente	Puntaje
Reconocimiento del conjunto de datos*	10
Lectura automatizada	15
Limpieza y preparación	15
Construcción de bases consolidadas	10
Caso de estudio 2022	15
Caso de estudio abril de 2024	20
Comparabilidad 2022–2024	10
Conclusiones y comunicación	5
TOTAL	**100**

* La obtención del dataset desde Kaggle es un requisito para desarrollar el parcial, pero no asigna ni descuenta puntos de manera independiente.

Nota del parcial = 1.0 + 4.0 × (Puntaje obtenido / 100)

DURACIÓN

El parcial será desarrollado durante una semana. El grupo deberá administrar el tiempo destinado a comprensión de los archivos, desarrollo del código, depuración, análisis, elaboración de visualizaciones e interpretación de resultados.

CONSIDERACIÓN FINAL

Este parcial trabaja con datos experimentales reales. Por esta razón, no necesariamente existe una única gráfica, procedimiento de limpieza o respuesta válida para todas las preguntas. Las decisiones tomadas deberán ser técnicamente razonables, reproducibles y estar justificadas mediante los datos.

Una respuesta correctamente argumentada que identifique que determinada comparación no puede realizarse de manera válida puede ser más apropiada que realizar una comparación únicamente porque los datos se encuentran disponibles.